

Sveučilište u Zagrebu
Fakultet elektrotehnike i računarstva

Baraa Yassin

**Autonomno prijanjanje bespilotne letjelice na granu bez
oslanjanja na sustav vanjskog pozicioniranja**

Zagreb, 2026.

Ovaj rad izrađen je u Laboratoriju za robotiku i inteligentne sustave upravljanja (LARICS), Zavod za automatiku i računalno inženjerstvo, Fakultet elektrotehnike i računarstva pod vodstvom prof. dr. sc. Matko Orsag i predan je na natječaj za dodjelu Rektorove nagrade u akademskoj godini 2025./2026.

Popis kratica

UAV *Unmanned Aerial Vehicle* – bespilotna letjelica

IBVS *Image-Based Visual Servoing* – vizualno serviranje temeljeno na slici

KLT *Kanade–Lucas–Tomasi* (praćenje značajki)

ToF *Time-of-Flight* – vremenski senzor udaljenosti

ROS *Robot Operating System*

UDP *User Datagram Protocol*

FCU *Flight Control Unit* – upravljačka jedinica leta

Sadržaj

1	Uvod	1
1.1	Povezani radovi	2
1.2	Pregled sustava	2
2	Hipoteza i ciljevi rada	4
2.1	Hipoteza	4
2.2	Ciljevi rada	4
3	Materijal i metode	5
3.1	Teorijska podloga	5
3.1.1	Segmentacija instanci	5
3.1.2	Rubna umjetna inteligencija i kvantizacija modela	5
3.1.3	Optički tok i praćenje značajki	5
3.1.4	Vizualno serviranje temeljeno na slici	6
3.2	Sklopovlje	6
3.2.1	Platforma letjelice	6
3.2.2	Računalo i senzori na letjelici	6
3.3	Implementacija sustava	7
3.3.1	Cjevovod za detekciju	7
3.3.2	Vizualno serviranje temeljeno na slici (IBVS)	7
3.3.3	Zamjena upravljačkog sloja	8
3.3.4	Manevar prijanjanja bez ToF okidača	8
3.3.5	Treniranje modela	9
4	Rezultati	10
5	Rasprava	11
6	Zaključci	12
	Popis literature	14

Poglavlje 1

Uvod

Prijanjanje (engl. *perching*) je biološki nadahnuta sposobnost bespilotnih letjelica (UAV) da se privremeno pričvrste ili usidre na strukturu iz svoje okoline, umjesto da neprestano lete ili slijeću na tlo. Takva sposobnost korisna je za produljenje trajanja misije bez punjenja baterije, prikupljanje uzoraka, nadzor i inspekciju te niz drugih zadataka u kojima letjelica ima koristi od mogućnosti da zaustavi let, zadrži položaj na strukturi i po potrebi nastavi letjeti.

Problem prijanjanja UAV-a dobro je poznat u istraživačkoj zajednici, a predložena su brojna rješenja, no nekoliko se izazova stalno ponavlja. Prvi je prostorna preciznost: točku prijanjanja potrebno je točno odrediti i neprekidno pratiti dok je letjelica u pokretu, bez gubitka cilja uslijed poremećaja ili prebacivanja na pogrešnu metu. Drugi je izazov upravljanja: izvođenje manevra prijanjanja zahtijeva veliku preciznost pri brzini kretanja, gdje se male pogreške u prilazu izravno odražavaju na uspješnost. Treći je izazov računalne prirode, budući da implementacije percepcije za prijanjanje UAV-a zahtijevaju izvođenje modela dubokog učenja (npr. YOLO ili RT-DETR) koji trebaju značajnu računalnu snagu za rad u stvarnom vremenu usporedno s ostalim dijelovima obrade i upravljanja letjelicom.

Ovaj rad nastavak je i prilagodba autorova prethodnog diplomskog rada [1], u kojem je razvijen cjeloviti sustav za percepciju i upravljanje koji cijelim tokom obrade radi na samoj letjelici. U diplomskom radu granu je detektirao model dubokog učenja za segmentaciju instanci pokrenut na rubnom akceleratoru, dobiveni kandidat za prijanjanje pratio se metodom optičkog toka, a upravljanje prilazom izvodilo se vizualnim serviranjem temeljenim na slici (IBVS), uz konačni manevr prijanjanja okinut očitanjem senzora udaljenosti (ToF) te uz oslanjanje na sustav OptiTrack za apsolutnu lokalizaciju letjelice.

Natjecateljski scenarij kojem je namijenjen ovaj rad razlikuje se od scenarija diplomskog rada u nekoliko bitnih pretpostavki. Letjelica polazi već pozicionirana neposredno ispod grane, čime se ukida potreba za fazom vodoravnog prilaska grani. Sustav vanjske lokalizacije OptiTrack nije dostupan, pa se upravljanje mora osloniti isključivo na podatke dostupne na samoj letjelici. Senzor udaljenosti (ToF) ne koristi se za okidanje manevra prijanjanja, budući da je namijenjen drugoj svrsi izvan opsega ovog rada. Konačno, kamera je fizički postavljena da gleda prema gore, a ne prema naprijed kao u izvornoj konfiguraciji, čime se mijenja geometrija

cijelog problema poravnanja i prilaska.

Ovaj rad opisuje ponovnu upotrebu i prilagodbu postojećeg cjevovoda za percepciju (detekcija grane, praćenje značajki) uz zamjenu upravljačkog sloja letjelice. Umjesto ROS čvora za upravljanje misijom prijanjanja razvijenog u sklopu diplomskog rada, koji je bio izravno ovisan o sustavu OptiTrack i o horizontalnoj geometriji prilaska, koristi se paket `ibvs_perching`, otvoreni ROS paket koji izravno upravlja letjelicom preko MAVROS-a slanjem naredbi kutne brzine tijela i brzine penjanja, bez oslanjanja na vanjski sustav pozicioniranja ili na kontroler pozicije unutar leta.

1.1 Povezani radovi

Detekcija grana za primjene na UAV-u dosad je istraživana u nekoliko smjerova. Silva i sur. [2] predložili su metodu detekcije linija temeljenu na konvolucijskoj neuronskoj mreži za prepoznavanje grana stabla iz digitalnih fotografija, koristeći Houghovu transformaciju za procjenu orijentacije grane i točke prihvata. Lin i sur. [3] usporedili su nekoliko modela dubokog učenja za segmentaciju u autonomnim šumarskim sustavima, dajući usporedbu performansi modela u stvarnim uvjetima. Oba rada usredotočena su isključivo na percepcijsku stranu problema, bez obrade cjelokupnog cjevovoda od detekcije do upravljanja.

Na strani upravljanja, Ji i sur. [4] predstavili su metodu planiranja trajektorije u stvarnom vremenu za zračno prijanjanje. Samadikhoshkho i Lipsett [5] kombinirali su duboko učenje s vizualnim serviranjem temeljenim na slici za zračno uzorkovanje vegetacije. Domišlović i sur. [6] demonstrirali su vizualno serviranje temeljeno na poziciji s marsupijalnim robotskim sustavom – pristup srodan onome korištenom u ovom radu. Kim i Chang [7] predstavili su sustav prijanjanja bez markera za kvadrokopter koji kombinira model segmentacije sa ToF senzorom i upravljačem temeljenim na konačnom automatu, izvodeći cijeli cjevovod na Jetson Orin NX platformi.

Za razliku od navedenih radova, koji redom pretpostavljaju letjelicu koja horizontalno prilazi meti uz raspoloživ sustav apsolutne lokalizacije, ovaj rad razmatra scenarij u kojem letjelica polazi već pozicionirana ispod cilja te se prijanjanje izvodi pretežno u vertikalnoj osi, bez oslanjanja na sustav vanjske lokalizacije poput OptiTracka.

1.2 Pregled sustava

Sustav zadržava podjelu na dva izvedbena okruženja iz diplomskog rada: Raspberry Pi OS, na kojem se izvodi percepcijski cjevovod, i Ubuntu unutar Docker kontejnera, na kojem se izvodi ROS upravljački sloj. Ta se podjela zadržava jer AI Hat+ akcelerator komunicira isključivo s Raspberry Pi OS okruženjem, pa sve što ovisi o slikovnim podacima ostaje na toj strani.

Na strani Raspberry Pi OS-a, cjevovod za detekciju grane preuzima okvire s kamere okrenute prema gore, provodi ih kroz model za segmentaciju instanci pokrenut na Hailo-8 akceleratoru te

ih obrađuje kroz cjevovod naknadne obrade i ocjenjivanja kandidata kako bi se odredila jedinstvena točka prijanjanja. Ta se točka potom proslijeđuje IBVS algoritmu koji izračunava vektor pogreške u odnosu na središte slike.

Na strani upravljanja letjelicom, umjesto prethodnog ROS čvora za misiju prijanjanja koji je koristio OptiTrack odometriju i dvokoračnu trajektoriju (poravnanje – vodoravni prilazak – prijanjanje), koristi se paket `ibvs_perching`. Taj paket izravno upravlja letjelicom preko sučelja `mavros/setpoint_raw/attitude`, šaljući naredbe kutne brzine tijela za bočno poravnanje i naredbu brzine penjanja za vertikalni prilazak, bez posredovanja kontrolera pozicije ili vanjskog sustava lokalizacije.

Poglavlje 2

Hipoteza i ciljevi rada

2.1 Hipoteza

Hipoteza ovog rada jest da se postojeći percepcijski cjevovod za detekciju i praćenje grane, razvijen za horizontalnu konfiguraciju kamere i prilazak s vanjskom lokalizacijom, može ponovno iskoristiti gotovo bez izmjena za scenarij u kojem je kamera okrenuta prema gore i u kojem letjelica ne raspolaže sustavom apsolutne lokalizacije, uz uvjet da se zamijeni isključivo upravljački sloj koji povezuje percepciju s naredbama letjelici.

2.2 Ciljevi rada

Glavni ciljevi ovog rada su:

1. Prilagoditi postojeći cjevovod za detekciju grane i praćenje točke prijanjanja (razvijen u sklopu diplomskog rada) novoj orijentaciji kamere (prema gore umjesto prema naprijed) i provjeriti da percepcijski dio sustava ostaje ispravan bez izmjena u geometriji obrade slike.
2. Zamijeniti upravljački ROS čvor koji je ovisio o sustavu OptiTrack i o senzoru udaljenosti (ToF) za okidanje manevra prijanjanja paketom `ibvs_perching`, koji upravlja letjelicom izravno preko MAVROS-a bez vanjske lokalizacije.
3. Odrediti i implementirati preslikavanje osi između izlaza percepcijskog cjevovoda (pogreška u slikovnoj ravnini) i naredbi tijela letjelice (kutne brzine, brzina penjanja), prilagođeno geometriji u kojoj letjelica polazi ispod grane i prijanjanje izvodi pretežno vertikalnim približavanjem.
4. Provesti eksperimentalnu provjeru prilagođenog sustava i usporediti ponašanje s onim opisanim u izvornom diplomskom radu.

Poglavlje 3

Materijal i metode

3.1 Teorijska podloga

3.1.1 Segmentacija instanci

Segmentacija instanci zadatak je računalnog vida koji kombinira detekciju objekata i semantičku segmentaciju. Za razliku od detekcije objekata, koja proizvodi samo okvire (*bounding box*), i semantičke segmentacije, koja svakom pikselu pridružuje oznaku klase bez razlikovanja pojedinačnih objekata, segmentacija instanci za svaku pojedinu instancu objekta u slici proizvodi i okvir i masku na razini piksela. Svakom pikselu unutar maske pridružuje se vrijednost pouzdanosti koja izražava vjerojatnost da pripada detektiranoj instanci.

3.1.2 Rubna umjetna inteligencija i kvantizacija modela

Rubna umjetna inteligencija (*edge AI*) odnosi se na izvođenje modela umjetne inteligencije izravno na ugrađenim ili rubnim uređajima, poput Raspberry Pi računala, umjesto oslanjanja na oblak ili poslužiteljsko računalstvo. Korišteni modeli u pravilu su istovjetni svojim punoopsežnim inačicama, uz ključnu razliku da su kvantizirani. Kvantizacija je postupak smanjenja preciznosti težina modela, tipično s 32-bitnog zapisa s pomičnim zarezom na 8-bitni cjelobrojni zapis, čime se znatno smanjuje potrošnja memorije i računalno opterećenje, omogućujući zaključivanje u stvarnom vremenu na maloj snazi.

3.1.3 Optički tok i praćenje značajki

Optički tok temelji se na praćenju istih značajki kroz više uzastopnih slika snimljenih u različitim trenucima. Pretpostavlja se da se osvjettljenje značajke ne mijenja bitno između slika. Značajke koje se prate prvo se identificiraju detektorom kutova poput FAST ili Harris, koji pronalazi točke u slici dovoljno izražene da se mogu pouzdano pratiti. Lokalni prozor oko svake značajke potom se koristi za pronalaženje njezinog odgovarajućeg položaja u sljedećoj slici minimizacijom

razlike u intenzitetu piksela. Ovakav pristup sužava prostor pretrage i čini postupak izvedivim u stvarnom vremenu.

3.1.4 Vizualno serviranje temeljeno na slici

Vizualno serviranje temeljeno na slici (IBVS) metoda je upravljanja koja slikovnu informaciju izravno koristi kao ulaz u upravljačku petlju. Pogreška se definira kao udaljenost u pikselima između detektirane točke prijanjanja i središta slike. Ta se pogreška dovodi proporcionalnom regulatoru koji generira naredbu brzine za letjelicu, vodeći točku prijanjanja prema središtu slike. Upravljačka petlja izvodi se kontinuirano: svaka iteracija preuzima novu sliku, ponovno izračunava pogrešku i izdaje novu naredbu brzine sve dok se pogreška ne minimizira.

3.2 Sklopovlje

3.2.1 Platforma letjelice

Letjelica korištena u ovom radu izgrađena je na 7-inčnom karbonskom okviru, odabranom zbog krutosti i male mase. Pogon osiguravaju četiri *brushless* motora T-Motor F90 2810 predviđena za propelere veličine 7 do 8 inča. Upravljanje letom obavlja SpeedyBee F405 upravljačka jedinica koja koristi MAVLink protokol za komunikaciju s računalom na letjelici.

U odnosu na konfiguraciju iz diplomskog rada, natjecateljski scenarij pretpostavlja drukčije postavljanje kamere – kamera je fizički okrenuta prema gore umjesto prema naprijed – što zahiti jeva novi nosač kamere te izmjenu geometrije preslikavanja pogreške iz slikovne ravnine u naredbe letjelici (vidi Odjeljak 3.3.3).

3.2.2 Računalo i senzori na letjelici

Računalo na letjelici je Raspberry Pi 5 s 8 GB radne memorije, uz Raspberry Pi AI Hat+ dodatak za sklopovski ubrzano zaključivanje modela. Kao izvor slike koristi se Arduino Nicla Vision kamera s integriranim ToF senzorom udaljenosti. Za razliku od diplomskog rada, u ovom se radu ToF očitavanje ne koristi za okidanje manevra prijanjanja – ono je predviđeno za drugu namjenu izvan opsega ovog rada – pa manevar prijanjanja mora biti okinut na temelju drugog signala (vidi Odjeljak 3.3.4).

Za prijanjanje se koristi prilagođeni 3D-tiskani pasivni hvataljka s oprugom, izrađena od PETG materijala, montirana na okvir letjelice. Hvataljka ostaje otvorena dok se na unutarnji dio čeljusti ne primijeni dovoljna sila, nakon čega se hvataljka zatvara.

3.3 Implementacija sustava

3.3.1 Cjevovod za detekciju

Cjevovod za detekciju grane preuzet je gotovo bez izmjena iz diplomskog rada, budući da je riječ o obradi isključivo u slikovnoj ravnini, neovisnoj o fizičkoj orijentaciji kamere u prostoru. Cjevovod je dizajniran modularno: svi razredi izvora slike dijele zajednički roditeljski razred, a svi koraci naknadne obrade nasljeđuju zajednički razred Stage. Podaci proizvedeni u svakom koraku pohranjuju se u strukturi PipelineContext, čime koraci nisu međusobno čvrsto povezani i mogu se zamjenjivati ili uklanjati bez utjecaja na ostatak cjevovoda.

Praćenje objekata provodi se algoritmom ByteTrack, koji kombinira Kalmanov filtar s Mađarskim algoritmom za povezivanje detekcija kroz uzastopne slike na temelju preklapanja okvira. Nakon toga slijede četiri koraka naknadne obrade: izdvajanje binarne maske pragiranjem izlazne pouzdanosti segmentacije, izračun mape udaljenosti (*distance heatmap*) Euklidskom transformacijom udaljenosti radi određivanja najdebljeg i najstabilnijeg dijela grane, računanje medijalne osi (kostura) binarne maske radi ograničavanja kandidata na središnjicu grane, te konačno bodovanje kandidata težinskom funkcijom koja kombinira pouzdanost detekcije, udaljenost od središta slike i veličinu detekcije.

Nakon početnog razdoblja zagrijavanja (*warmup*) od približno 20 sekundi, tijekom kojeg se prikupljaju najbolji kandidati iz svake slike, prikupljene točke grupiraju se algoritmom hijerarhijskog grupiranja s pragom udaljenosti od 30 piksela. Najpopunjenija skupina odabire se kao konačna točka prijanjanja (*final point*), nakon čega se model detekcije prestaje izvoditi, a praćenje preuzima KLT algoritam opisan u nastavku.

3.3.2 Vizualno serviranje temeljeno na slici (IBVS)

Nakon zaključavanja konačne točke, IBVS izdvaja FAST i Harris kutne značajke iz referentne slike u lokalnoj okolini točke prijanjanja te pohranjuje pomak svake značajke u odnosu na tu točku. U svakoj sljedećoj slici značajke se prate KLT (*Kanade–Lucas–Tomasi*) algoritmom optičkog toka, a položaj točke prijanjanja procjenjuje se primjenom pohranjenih pomaka na trenutne položaje praćenih značajki. Time se izbjegava ponovno pokretanje modela detekcije za svaku sliku, čime se smanjuje računalno opterećenje i omogućuje praćenje u stvarnom vremenu.

Pogreška se računa kao udaljenost u pikselima između procijenjenog položaja točke prijanjanja i središta slike, zasebno za vodoravnu i okomitu os. Ova komponenta sustava također se preuzima bez izmjena iz diplomskog rada, jer izlaz IBVS-a ostaje par vrijednosti pogreške u slikovnoj ravnini (*error_x*, *error_y*) bez ugrađene pretpostavke o fizičkoj orijentaciji kamere – preslikavanje tih vrijednosti u naredbe letjelici u potpunosti je izmješteno u upravljački sloj opisan u nastavku.

3.3.3 Zamjena upravljačkog sloja

U diplomskom radu upravljanje letjelicom izvodio je namjenski razvijeni ROS čvor koji je koristio OptiTrack odometriju za apsolutno pozicioniranje te trokoračni konačni automat (ALIGNING – APPROACHING – PERCHING) u kojem su ispravci iz IBVS-a preslikavani u naredbe apsolutnog položaja: vodoravna pogreška slike preslikavala se u y-os letjelice, okomita pogreška u z-os, dok se x-os (smjer prilaska) pomicala unaprijed fiksnim korakom sve dok ToF senzor ne bi zabilježio udaljenost ispod praga, nakon čega bi se izvela dvokoračna trajektorija prijanjanja.

Budući da natjecateljski scenarij ne raspolaže sustavom OptiTrack niti koristi ToF senzor za okidanje prijanjanja, taj se upravljački čvor u potpunosti zamjenjuje otvorenim paketom `ibvs_perching` [8]. Taj paket ne koristi kontroler pozicije niti vanjsku lokalizaciju: letjelicom upravlja izravno preko sučelja `mavros/setpoint_raw/attitude`, šaljući naredbe kutne brzine tijela (*body rate*) za bočno poravnanje te naredbu brzine penjanja (kroz polje `thrust`, protumačeno u ArduPilot GUIDED načinu rada kao naredba brzine penjanja, a ne kao sirovi potisak) za okomiti prilazak.

Sučelje između percepcije i ovog upravljačkog sloja jest poruka `PointStamped` na temi `ibvs/target_point`, u kojoj x i y predstavljaju normaliziran pomak ciljne točke od središta slike, a z (opcionally) procijenjenu udaljenost do cilja. Ovime se zadržava jasna granica između percepcijskog cjevovoda (koji ne zna ništa o geometriji letjelice) i upravljačkog sloja (koji ne zna ništa o tome kako je točka detektirana) – ista podjela odgovornosti koja je postojala i u izvornom sustavu iz diplomskog rada.

Preslikavanje osi za kameru okrenutu prema gore

Paket `ibvs_perching` izvorno pretpostavlja kameru okrenutu prema dolje, gdje vodoravni pomak u slici (`point.x`) odgovara pomaku unaprijed u koordinatnom sustavu letjelice, a okomiti pomak u slici (`point.y`) odgovara pomaku ulijevo/udesno. Budući da je u ovom radu kamera okrenuta prema gore, a letjelica polazi već pozicionirana ispod grane, preslikavanje osi mora se iznova izvesti: os prilaska više nije vodoravna os letjelice (naprijed), nego okomita os (penjanje), dok se poravnanje u preostale dvije osi izvodi analogno prethodnom sustavu.

3.3.4 Manevar prijanjanja bez ToF okidača

Budući da senzor udaljenosti nije dostupan za okidanje manevra prijanjanja, potreban je drukčiji signal za prijelaz iz faze poravnanja u fazu izvođenja manevra. Kako letjelica polazi s poznate, fiksne udaljenosti ispod grane, razmatra se okidanje na temelju vremena provedenog u stanju poravnanja unutar zadanog praga pogreške, umjesto na temelju izravnog mjerenja udaljenosti.

3.3.5 Treniranje modela

Model za segmentaciju grana (YOLOv8m-seg) preuzet je bez izmjena iz diplomskog rada. Skup podataka za treniranje sastojao se od fotografija grana snimljenih iz bočne perspektive, a maske za segmentaciju automatski su generirane modelom SAM3 na temelju tekstualnog upita. Model je izvezen u ONNX format i zatim kompiliran u Hailo izvršni format (.hef) za izvođenje na Raspberry Pi AI Hat+ akceleratoru.

Poglavlje 4

Rezultati

Ovo poglavlje bit će dovršeno nakon provedbe eksperimenata.

Poglavlje 5

Rasprava

Ovo poglavlje bit će dovršeno nakon provedbe eksperimenata.

Poglavlje 6

Zaključci

Ovo poglavlje bit će dovršeno nakon provedbe eksperimenata.

Zahvale

Zahvaljujem prof. dr. sc. Matku Orsagu i svim članovima LARICS laboratorija na podršci, savjetima i pomoći tijekom izrade ovog rada.

Popis literature

- [1] Baraa Yassin. *Development of a Control System for a Small Unmanned Aerial Vehicle with Perching Capability*. Diplomski rad, Fakultet elektrotehnike i računarstva, Sveučilište u Zagrebu. Mentor: prof. dr. sc. Matko Orsag. 2026.
- [2] Rodrigo Silva i dr. „Line-based deep learning method for tree branch detection from digital images”. *International Journal of Applied Earth Observation and Geoinformation* 110 (2022.), str. 102759. ISSN: 1569-8432. DOI: <https://doi.org/10.1016/j.jag.2022.102759>. URL: <https://www.sciencedirect.com/science/article/pii/S030324342200085X>.
- [3] Yida Lin i dr. *Performance Evaluation of Deep Learning for Tree Branch Segmentation in Autonomous Forestry Systems*. 2025. arXiv: 2512.05418 [cs.CV]. URL: <https://arxiv.org/abs/2512.05418>.
- [4] Jialin Ji i dr. *Real-Time Trajectory Planning for Aerial Perching*. 2022. arXiv: 2203.01061 [cs.RO]. URL: <https://arxiv.org/abs/2203.01061>.
- [5] Zahra Samadikhoshkho i Michael G. Lipsett. „Visual Servoing for Aerial Vegetation Sampling Systems”. *Drones* 8.11 (2024.). ISSN: 2504-446X. DOI: 10.3390/drones8110605. URL: <https://www.mdpi.com/2504-446X/8/11/605>.
- [6] Jakob Domislovic i dr. „Position-Based Visual Servoing With a Marsupial Robotic System”. *IEEE Access* 14 (2026.), str. 99210–99226. DOI: 10.1109/ACCESS.2026.3707289.
- [7] Donghyun Kim i Dong Eui Chang. „An Onboard Integrated Perception and Control Framework for Autonomous Quadrotor UAV Perching on Markerless Hurdles”. *Drones* 10.4 (2026.), str. 270. DOI: 10.3390/drones10040270.
- [8] Jakob Domišlović. *ibvs_perching: Image-Based Visual Servoing for AR-tag Perching with Direct Body-Rate Control through MAVROS*. https://github.com/JakobDomislovic/ibvs_perching. visited on 2026-08-02. 2026.

Sažetak

Baraa Yassin

Autonomno prijanjanje bespilotne letjelice na granu bez oslanjanja na sustav vanjskog pozicioniranja

Ovaj rad opisuje prilagodbu sustava za autonomno prijanjanje bespilotne letjelice na granu, izvorno razvijenog u sklopu diplomskog rada, za natjecateljski scenarij u kojem letjelica polazi već pozicionirana ispod grane, bez oslanjanja na sustav vanjske lokalizacije OptiTrack te bez korištenja senzora udaljenosti (ToF) za okidanje manevra prijanjanja. Fizička orijentacija kamere također je izmijenjena, s izvorne vodoravne (prema naprijed) na okomitu (prema gore). Percepcijski cjevovod za detekciju grane i praćenje točke prijanjanja, koji radi isključivo u slikovnoj ravnini, preuzet je bez izmjena, dok je upravljački ROS čvor koji je ovisio o vanjskoj lokalizaciji zamijenjen otvorenim paketom `ibvs_perching`, koji letjelicom upravlja izravno preko MAVROS-a naredbama kutne brzine tijela i brzine penjanja. Rad opisuje potrebno preslikavanje osi između izlaza percepcije i naredbi letjelici u novoj geometriji te [TODO: dopuniti rezultatima eksperimentalne provjere].

Ključne riječi: bespilotna letjelica, prijanjanje na granu, vizualno serviranje temeljeno na slici, autonomno upravljanje, računalni vid

Summary

Baraa Yassin

Autonomous UAV Branch Perching Without External Positioning

This paper describes the adaptation of an autonomous UAV branch-perching system, originally developed as part of a master's thesis, for a competition scenario in which the UAV starts already positioned beneath the branch, without relying on the OptiTrack external localization system and without using a time-of-flight (ToF) sensor to trigger the perching maneuver. The physical camera orientation has also changed, from the original forward-facing mount to an upward-facing one. The perception pipeline for branch detection and perch-point tracking, which operates purely in the image plane, is reused unchanged, while the ROS control node that depended on external localization is replaced with the open-source `ibvs_perching` package, which commands the UAV directly through MAVROS using body-rate and climb-rate commands. The paper describes the axis remapping required between the perception output and the UAV commands in the new geometry, and [TODO: complete with experimental validation results].

Key words: unmanned aerial vehicle, branch perching, image-based visual servoing, autonomous control, computer vision